

Анализ выразительности и обобщающей способности LoRA

Охотников Н.В.

Научный руководитель: Грабовой А.В. к.ф.-м.н.

МФТИ

2026

Цель

Предложить улучшение теоретических оценок выразительности и обобщающей способности нейронных сетей, обучаемых методом LoRA

Проблема

Известные оценки не учитывают неявные ограничения процесса оптимизации при обучении с LoRA

Предлагается

Использовать эмпирическое ограничение на stable rank матриц адаптеров.
Уточнить оптимальное решение задачи аппроксимации матрицы матрицей меньшего ранга с учетом дополнительного ограничения на stable rank.
Использовать PAC-Bayes фреймворк для улучшения оценки обобщающей способности.

Аппроксимация отдельной матрицы

$$\text{Stable rank матрицы } A : sr(A) = \frac{\|A\|_F^2}{\|A\|_{op}^2} = \frac{\sum_i \sigma_i^2(A)}{\sigma_1^2(A)}$$

$$\mathcal{M}_{R,S}^{d,d} \subset \mathbb{R}^{d \times d}, \forall A \in \mathcal{M}_{R,S}^{d,d} : rank(A) \leq R, sr(A) \leq S$$

Пусть $A \in \mathbb{R}^{d \times d}$, $A_R = \sum_{i=1}^R \sigma_i u_i v_i^T$ - оптимальная (по норме Фробениуса) аппроксимация A матрицей ранга R (из сингулярного разложения)

Пусть $\hat{A} \in \mathcal{M}_{R,S}^{d,d}$ такова, что $\inf_{\tilde{A} \in \mathcal{M}_{R,S}^{d,d}} \|A - \tilde{A}\|_F^2 = \|A - \hat{A}\|_F^2$

Лемма 1 [Охотников, 2026]

$$\hat{A} = \sum_{i=1}^R \hat{\sigma}_i u_i v_i^T, \quad \text{где } \hat{\sigma}_i = \sigma_i, \text{ если } sr(A_R) \leq S, \text{ иначе:}$$

$$\hat{\sigma}_1 = \frac{\sigma_1 + \sqrt{S-1} \sqrt{\sum_{j=2}^R \sigma_j^2}}{S}, \quad \hat{\sigma}_i = \gamma \sigma_i \quad (i \geq 2), \quad \gamma = \frac{\sqrt{S-1} \hat{\sigma}_1}{\sqrt{\sum_{j=2}^R \sigma_j^2}}$$

Причём $\|A - \hat{A}\|_F^2 = \sum_{i=R+1}^D \sigma_i^2 + \Delta_S$, $\Delta_S = 0$, если $sr(A_R) \leq S$, иначе:

$$\Delta_S = \frac{1}{S} \left(\sqrt{\sum_{i=2}^R \sigma_i^2} - \sqrt{S-1} \sigma_1 \right)^2$$

Выразительность в полносвязной сети

Обозначения

целевая FNN $\bar{f} := FNN_{L,D}(\cdot; (\bar{W}_l)_{l=1}^L, (\bar{b}_l)_{l=1}^L)$, - хотим приблизить

предобученная FNN $f_0 := FNN_{L,D}(\cdot; (W_l)_{l=1}^L, (b_l)_{l=1}^L)$,

предобученная с адаптером FNN $f := FNN_{L,D}(\cdot; (W_l + \Delta W_l)_{l=1}^L, (\hat{b}_l)_{l=1}^L)$
 $b_l, \bar{b}_l, \hat{b}_l \in \mathbb{R}^D$, $W_l, \bar{W}_l, \Delta W_l \in \mathbb{R}^{D \times D}$, $\Delta W_l = A_l B_l$, где $A_l \in \mathbb{R}^{D \times R}$ и $B_l \in \mathbb{R}^{R \times D}$ и $R \leq D$ – ранг LoRA.

Теорема 1 (Выразительность LoRA для FFN) [Охотников, 2026]

Пусть $x \in \mathbb{R}^d$ случайный вектор с ковариационно матрицей $\Sigma = \mathbb{E}[xx^T]$.

Пусть $E_l = \bar{W}_l - W_l$. Пусть $E_{l,R}$ оптимальная аппроксимация ранга R с $\sigma_{l,1} \geq \dots \geq \sigma_{l,R}$. Пусть $\hat{b}_l = \bar{b}_l$. Тогда $\exists \{\Delta W_l\}_{l=1}^L \subset \mathcal{M}_{R,S}^{D,D}$ такие что:

$$\mathbb{E} \|f(x) - \bar{f}(x)\|_2 \leq \beta \sum_{l=1}^L \left(\prod_{k=l+1}^L \|\bar{W}_k\|_2 \right) \mathcal{T}_l, \text{ где}$$

$$\beta = \max_{i \in [L]} \left(\left(\prod_{j=1}^i \|\bar{W}_j\| \right) \sqrt{\text{tr}(\Sigma)} + \sum_{j=1}^i \left(\prod_{k=j+1}^i \|\bar{W}_k\| \right) \|\bar{b}_j\| \right)$$

$$\text{и } \mathcal{T}_l = \sqrt{\sum_{j=R+1}^D \sigma_{l,j}^2 + \Delta_{S,l}}, \text{ где}$$

$$\Delta_{S,l} = \frac{1}{S} \left(\sqrt{\sum_{j=2}^R \sigma_{l,j}^2} - \sqrt{S-1} \sigma_{l,1} \right)^2 \text{ если } \text{sr}(E_{l,R}) > S, \text{ иначе } 0$$

Выразительность в архитектуре transformer

Обозначения

Трансформер L блоков – H -головый self-attention + 2-слоный FFN, без dropout/нормализаций, но со skip connection

Целевая сеть $\bar{f}$, замороженная f_0 , адаптированная f (LoRA на всех Q, K, V, O , обоих слоях FFN).

$\mathcal{T}(G) = \sqrt{\sum_{i=R+1}^D \sigma_i^2(G) + \Delta_S(G)}$ – ошибка для матрицы G из **Леммы 1**.

Теорема 2(Выразительность LoRA для Transformer) [Охотников, 2026]

Существует набор матриц адаптеров $\{\Delta W\} \subset \mathcal{M}_{R,S}^{D,D}$ с $SR \leq S$ такой, что

$$\mathbb{E} \|f(x) - \bar{f}(x)\|_F \leq \beta \sum_{l=1}^L \left(\prod_{k=l+1}^L \gamma_k \right) \mathcal{D}_l$$

- γ_k : константа Липшица целевого блока k по входу (через FFN + МНА)
- $\mathcal{D}_l = \mathcal{T}_{2,l} + \|\overline{W_{2,l}}\| \mathcal{T}_{1,l} + \|\overline{W_{2,l}}\| \|\overline{W_{1,l}}\| \sum_h \mathcal{D}_{att,l}^h$ (ошибки FFN + attention)
- $\mathcal{D}_{att,l}^h$: ошибка головы $\propto \mathcal{T}_O, \mathcal{T}_V, \mathcal{T}_Q, \mathcal{T}_K$

Оценка обобщающей способности

Обозначения

Полносвязная сеть глубины T , ширины d f_W , с 1-липшицевой функцией активации $\sigma(\cdot)$, $\sigma(0) = 0$, LoRA на каждом слое $\Delta W_t = B_t A_t^T$,

$W_t = W_{0,t} + \Delta W_t$. $\|\Delta W_t\|_{op} \leq \Lambda_t$, $\text{sr}(\Delta W_t) \leq S_t$, пусть вход $x_i : \|x_i\|_2 \leq B_x$

Margin: $m(f_W(x), y) = f_W(x)_y - \max_{j \neq y} f_W(x)_j$

$$L_\gamma(W) = \mathbb{P}_{(x,y)}[m(f_W(x), y) \leq \gamma], \quad \hat{L}_\gamma(W) = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[m(f_W(x_i), y_i) \leq \gamma]$$

L_0 – истинный риск. Generalisation gap $G = \sup_{f_W} |L_0 - \hat{L}_0|$

Теорема 3 (Обобщающая способность LoRA) [Охотников, 2026]

$\forall \gamma > 0$ и любых ΔW_t , удовлетворяющего указанным выше условиям, с вероятностью не менее $1 - \delta$ по выбору обучающей выборки размера N :

$$L_0(W) \leq \hat{L}_\gamma(W) + \mathcal{O} \left(\sqrt{\frac{B_x^2 T^2 (d + \ln(TN)) (\prod_{t=1}^T \bar{\beta}_t^2) \sum_{t=1}^T \frac{\Lambda_t^2 S_t}{\bar{\beta}_t^2} + \log(N/\delta)}{\gamma^2 N}} \right)$$

$\mathcal{O}(\sqrt{S/N})$ в отличие от наилучшего ранее известного $\mathcal{O}(\sqrt{r/N})$.

Эксперимент

Архитектура: MLP ширина $D = 128$, глубина $L = 10$. Схема «учитель–ученик».

Инициализация: одинаковые веса ученика и учителя, далее сдвиги ΔW_l для весов учителя с разным SR

Контроль SR: $U \text{diag}(\sigma) V^T$ – SVD случайной матрицы, далее $\sigma_1 \rightarrow \sigma_1 \cdot c_i$, где $c_1 \dots c_8 = \{1.0, 1.5, 2.0, 3.0, 5.0, 8.0, 12.0, 20.0\}$




Данные: $x \sim \mathcal{N}(0, I) \rightarrow$ учитель $+ \varepsilon \rightarrow y$, $N_{\text{train}} = 2048$, $N_{\text{val}} = 10240$.

LoRA: ранги $r \in \{4, 6, 8, 12, 16, 24, 32, 48, 64, 96, 128\}$ + полное дообучение

Обучение: AdamW, 200 эпох, $lr = 10^{-3}$.

Метрики: Generalization gap = $\text{loss}(\text{valid}) - \text{loss}(\text{train})$. Средний stable rank $\overline{\text{sr}}$ адаптеров.

Результаты эксперимента



Выносятся на защиту

1. Доказана лемма для оптимальной аппроксимации матрицы матрицей с рангом $\leq R$ и $\text{stable rank} \leq S$
2. Уточнены границы выразительности LoRA для FNN и Transformer с учётом stable rank
3. Усилена верхняя оценка на $\text{generalisation gap}$ для LoRA с $\mathcal{O}(\sqrt{R/N})$ до $\mathcal{O}(\sqrt{S/N})$
4. Экспериментально показано, что $\propto \sqrt{S}$ лучше чем $\propto \sqrt{R}$ приближает динамику $\text{generalisation gap}$ при изменении гиперпараметров
5. Экспериментально показано, что stable rank является лучшим чем алгебраический ранг индикатором для масштабирования обобщающей способности и выразительности